KLASIFIKASI CITRA SAMPAH MENGGUNAKAN ARSITEKTUR MOBILENETV2

Disusun Untuk Memenuhi Tugas Mata Kuliah Deep Learning-A

Dosen Pengampu:

Wahyudi Setiawan

Oleh :

Belia Eka Sukma Mentari	(230441100110)
Annisa Putri	(230441100133)
Dio Ramadhani Pratama P	(230441100142)
Nagita Brenda Silvia	(230441100152)

PROGRAM STUDI SISTEM INFORMASI

FAKULTAS TEKNIK

UNIVERSITAS TRUNOJODJOYO MADURA

2026

1. Pendahuluan

Klasifikasi citra merupakan salah satu penerapan deep learning yang digunakan untuk mengidentifikasi objek berdasarkan informasi visual pada citra. Pada tugas ini dilakukan klasifikasi citra sampah menggunakan Convolutional Neural Network (CNN) berbasis arsitektur MobileNetV2. Dataset terdiri dari empat kelas sampah, yaitu wood_waste, paper_waste, plastic_bottles, dan metal_cans. Setiap kelas digunakan sebanyak 50 citra sehingga keseluruhan dataset berjumlah 200 citra.

Eksperimen dilakukan menggunakan empat skenario untuk mengetahui pengaruh perbedaan konfigurasi terhadap kinerja model. Evaluasi dilakukan menggunakan accuracy, precision, recall, F1-score, dan confusion matrix.

2. Dataset

Dataset yang digunakan berisi empat kelas citra sampah. Masing-masing kelas terdiri atas 50 citra sehingga jumlah keseluruhan adalah 200 citra.

No	Kelas	Jumlah Citra
1	wood_waste	50
2	paper_waste	50
3	plastic_bottles	50
4	metal_cans	50

Dataset dibagi menjadi data training, validation, dan testing. Dengan pembagian 70%:15%:15%, diperoleh 140 citra training, 28 citra validation, dan 32 citra testing. Setiap kelas memiliki 35 citra untuk training, 7 citra untuk validation, dan 8 citra untuk testing.

3. Metode Penelitian

3.1 Prepocessing

Seluruh citra diubah ukurannya menjadi 224×224 piksel agar sesuai dengan ukuran input MobileNetV2. Nilai piksel kemudian dinormalisasi menggunakan rescale 1/255. Pada skenario yang menggunakan augmentation, dilakukan rotasi, pergeseran posisi, zoom, dan horizontal flip.

3.2 Arsitektur MobileNetV2

MobileNetV2 digunakan sebagai model dasar karena merupakan arsitektur CNN yang relatif ringan dan sesuai untuk eksperimen dengan jumlah data yang terbatas. Pada bagian akhir model digunakan Global Average Pooling, Dropout, dan Dense dengan empat neuron serta fungsi aktivasi softmax untuk menghasilkan prediksi empat kelas.

3.3 Skenario Pengujian

No	Konfigurasi	Jumlah Citra
1	Baseline	MobileNetV2 dengan preprocessing dasar tanpa augmentation
2	Augmentation	MobileNetV2 dengan data augmentation pada data training.
3	Augmentation + Dropout 0,4	Augmentation ditambah Dropout 0,4 pada classifier.
4	Fine-tuning MobileNetV2	Sebagian layer akhir MobileNetV2 dibuka untuk fine-tuning dengan learning rate 0,0001.

4. Hasil Pengujian

Pengujian dilakukan terhadap 32 citra testing yang tidak digunakan selama proses training. Hasil evaluasi empat skenario ditunjukkan pada tabel berikut.

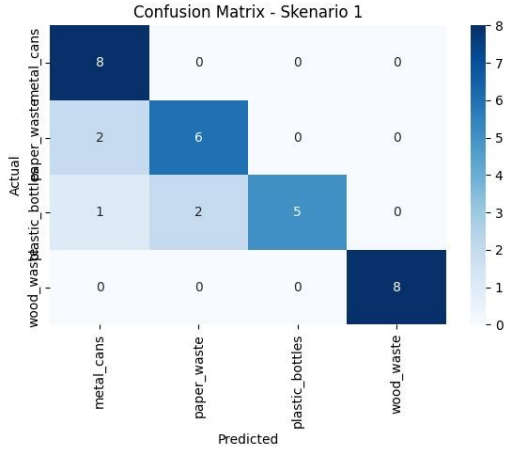
Skenario	Perlakuan	Accuracy	Precision	Recall	F1-Score
1	Baseline	84,38%	86,93%	84,38%	84,03%
2	Augmentation	84,38%	85,44%	84,38%	83,91%
3	Augmentation + Dropout 0,4	87,50%	90,06%	87,50%	87,16%
4	Fine-tuning MobileNetV2	71,88%	77,32%	71,88%	69,27%

Interpretasi hasil:

Skenario 1 dan Skenario 2 menghasilkan accuracy yang sama, yaitu 84,38%. Skenario 3 menghasilkan nilai metrik pengujian tertinggi pada eksperimen ini, dengan accuracy 87,50%, precision 90,06%, recall 87,50%, dan F1-score 87,16%. Sementara itu, Skenario 4 memperoleh accuracy 71,88% dan F1-score 69,27%, sehingga konfigurasi fine-tuning yang digunakan pada eksperimen ini tidak meningkatkan performa model pada dataset yang digunakan.

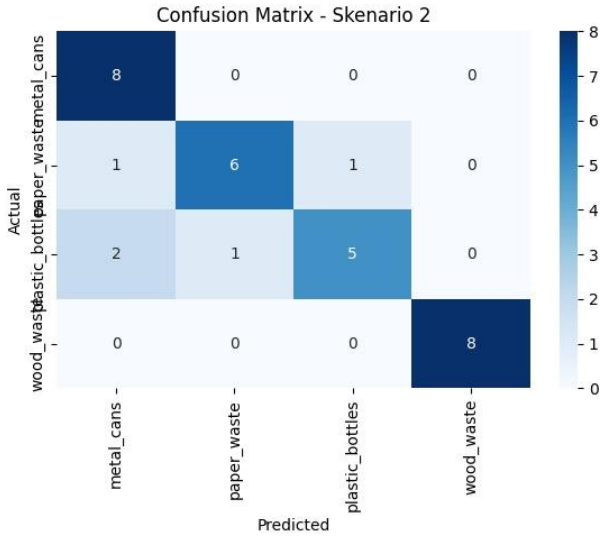
5. Confusion Matrix

Confusion matrix digunakan untuk melihat distribusi hasil prediksi benar dan salah pada masing-masing kelas. Confusion matrix dibuat untuk keempat skenario pengujian sehingga dapat dibandingkan pola kesalahan klasifikasi yang dihasilkan oleh setiap konfigurasi model.



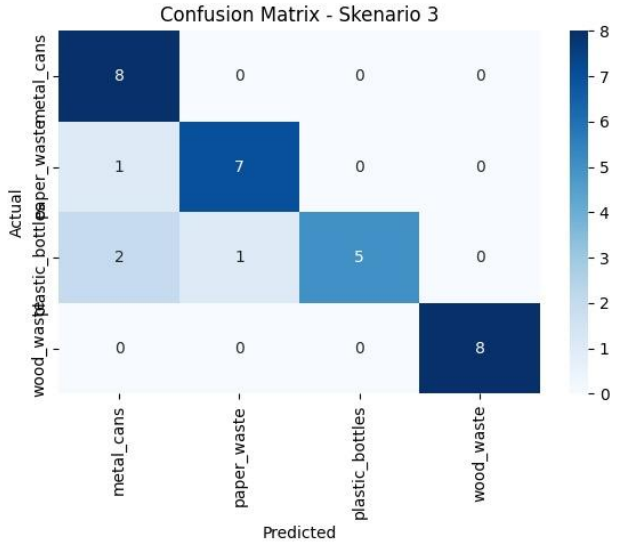
Gambar 1. Confusion Matrix Skenario 1

Interpretasi: Berdasarkan confusion matrix pada Skenario 1, model melakukan klasifikasi terhadap 32 data testing yang terdiri dari empat kelas, yaitu metal_cans, paper_waste, plastic_bottles, dan wood_waste. Pada kelas metal_cans, sebanyak 8 citra berhasil diklasifikasikan dengan benar sebagai metal_cans. Pada kelas paper_waste, terdapat 6 citra yang diklasifikasikan dengan benar, sedangkan 2 citra salah diklasifikasikan sebagai metal_cans. Pada kelas plastic_bottles, sebanyak 5 citra berhasil diklasifikasikan dengan benar, sementara 1 citra diklasifikasikan sebagai metal_cans dan 2 citra sebagai paper_waste. Sementara itu, seluruh 8 citra wood_waste berhasil diklasifikasikan dengan benar. Secara keseluruhan, model berhasil mengklasifikasikan 27 dari 32 citra dengan benar, sehingga diperoleh nilai accuracy sebesar 84,38%. Kesalahan klasifikasi paling banyak terjadi pada kelas plastic_bottles, yaitu sebanyak 3 citra, sedangkan kelas wood_waste tidak mengalami kesalahan klasifikasi. Hasil tersebut menunjukkan bahwa pada Skenario 1 model sudah mampu membedakan keempat kelas sampah, tetapi masih terdapat kesulitan dalam membedakan beberapa citra paper_waste dan plastic_bottles dengan metal_cans maupun paper_waste.



Gambar 2. Confusion Matrix Skenario 2

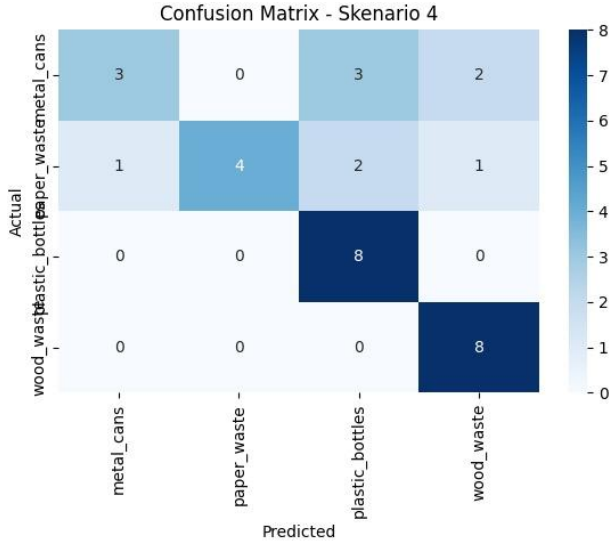
Interpretasi: Berdasarkan confusion matrix Skenario 2, model berhasil melakukan klasifikasi dengan cukup baik pada empat kategori sampah, yaitu metal_cans, paper_waste, plastic_bottles, dan wood_waste. Kelas metal_cans dan wood_waste memiliki hasil terbaik karena seluruh data berhasil diprediksi dengan benar, masing-masing sebanyak 8 data. Pada kelas paper_waste, terdapat 6 data yang benar, dengan beberapa kesalahan klasifikasi menjadi metal_cans dan plastic_bottles. Sementara itu, kelas plastic_bottles memperoleh 5 prediksi benar, tetapi masih mengalami kesalahan karena beberapa data tertukar dengan metal_cans dan paper_waste. Secara keseluruhan, model berhasil mengklasifikasikan 27 dari 32 data dengan benar atau memiliki akurasi sekitar 84,38%. Kesalahan paling banyak terjadi pada kategori plastic_bottles, yang menunjukkan bahwa model masih mengalami kesulitan membedakan sampah plastik dengan jenis sampah lain yang memiliki kemiripan visual.



Gambar 3. Confusion Matrix Skenario 3

Interpretasi: Berdasarkan confusion matrix Skenario 3, model menunjukkan kemampuan klasifikasi yang baik pada empat kategori sampah, yaitu metal_cans, paper_waste, plastic_bottles, dan wood_waste. Kelas metal_cans dan wood_waste

berhasil diklasifikasikan dengan sempurna, yaitu seluruh 8 data berhasil diprediksi dengan benar. Pada kelas paper_waste, terdapat 7 data yang diklasifikasikan dengan tepat, sementara 1 data salah diprediksi sebagai metal_cans. Kelas plastic_bottles memperoleh 5 prediksi benar, dengan beberapa kesalahan yaitu 2 data tertukar menjadi metal_cans dan 1 data menjadi paper_waste. Secara keseluruhan, model berhasil mengklasifikasikan 28 dari 32 data dengan benar dengan akurasi sekitar 87,50%. Kesalahan masih terjadi terutama pada kelas plastic_bottles yang memiliki kemiripan karakteristik visual dengan kategori lain. Namun, dibandingkan Skenario 2, performa model mengalami peningkatan karena jumlah kesalahan klasifikasi berkurang.



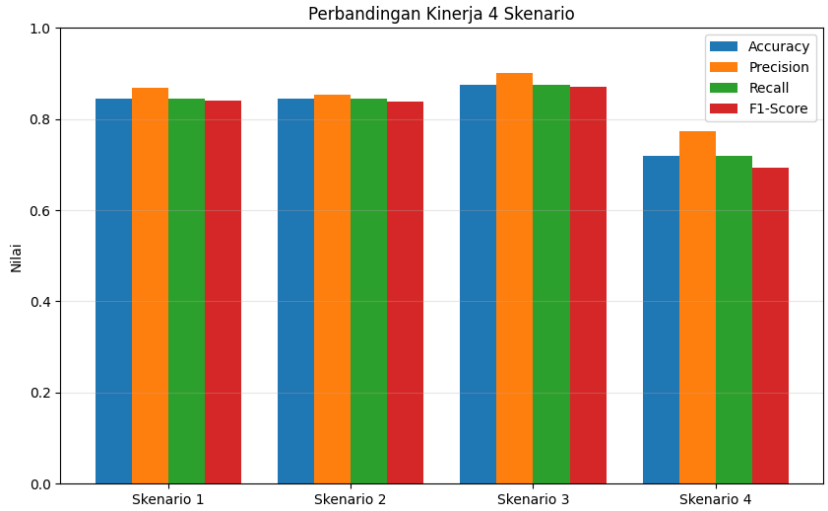
Gambar 4. Confusion Matrix Skenario 4

Interpretasi: Berdasarkan confusion matrix Skenario 4, performa model menunjukkan hasil yang bervariasi pada setiap kategori sampah, yaitu metal_cans, paper_waste, plastic_bottles, dan wood_waste. Kelas plastic_bottles dan wood_waste berhasil diklasifikasikan dengan sangat baik, dengan seluruh 8 data berhasil diprediksi secara benar. Pada kelas metal_cans, hanya 3 data yang berhasil diklasifikasikan dengan tepat, sementara beberapa data salah diprediksi sebagai plastic_bottles (3 data) dan wood_waste (2 data). Kelas paper_waste memperoleh

4 prediksi benar, dengan kesalahan klasifikasi menjadi metal_cans (1 data), plastic_bottles (2 data), dan wood_waste (1 data). Secara keseluruhan, model berhasil mengklasifikasikan 23 dari 32 data dengan benar atau memperoleh akurasi sekitar 71,88%. Kesalahan terbesar terjadi pada kelas metal_cans dan paper_waste yang masih sering tertukar dengan kategori lain. Meskipun beberapa kelas seperti plastic_bottles dan wood_waste memiliki performa yang sangat baik, hasil ini menunjukkan bahwa model masih perlu ditingkatkan dalam membedakan karakteristik visual sampah yang memiliki kemiripan.

6. Perbandingan Kerja

Perbandingan keempat skenario menunjukkan adanya perbedaan performa setelah perubahan konfigurasi model. Skenario 3 memberikan nilai accuracy, precision, recall, dan F1-score yang lebih tinggi dibandingkan tiga konfigurasi lainnya pada data testing.



Gambar 5. Perbandingan Kinerja 4 Skenario

7. Pembahasan

Hasil eksperimen menunjukkan bahwa konfigurasi model memberikan pengaruh terhadap kinerja klasifikasi. Penambahan augmentation pada Skenario 2 belum mengubah accuracy dibandingkan baseline. Pada Skenario 3, penambahan

Dropout 0,4 menghasilkan peningkatan accuracy dari 84,38% menjadi 87,50% serta peningkatan F1-score dari 84,03% pada baseline menjadi 87,16%.

Berbeda dengan Skenario 3, fine-tuning pada Skenario 4 menghasilkan penurunan performa. Hal ini menunjukkan bahwa membuka sebagian layer pretrained tidak selalu menghasilkan peningkatan, terutama pada dataset yang relatif kecil. Oleh karena itu, hasil eksperimen menunjukkan bahwa konfigurasi augmentation dan Dropout 0,4 memberikan hasil pengujian yang lebih tinggi dalam empat konfigurasi yang diuji.

8. Kesimpulan

Berdasarkan eksperimen klasifikasi citra menggunakan MobileNetV2 pada empat kelas sampah dengan total 200 citra, dapat disimpulkan bahwa model mampu melakukan klasifikasi dengan tingkat kinerja yang berbeda pada setiap konfigurasi. Dari empat skenario yang diuji, Skenario 3, yaitu penggunaan data augmentation dan Dropout 0,4, menghasilkan nilai metrik pengujian tertinggi pada dataset ini, dengan accuracy 87,50%, precision 90,06%, recall 87,50%, dan F1-score 87,16%. Skenario 4 dengan fine-tuning menghasilkan accuracy 71,88%, sehingga konfigurasi fine-tuning yang digunakan belum memberikan peningkatan performa pada eksperimen ini.